Михаил Бальхаев

ML Engineer / Generative AI Engineer / Product Developer

Москва m.balkhaev@gmail.com +7 966 006-60-68 t.me/balkhaev balkhaev.com



ML-инженер в генеративном AI: диффузия для фото и видео, синтез речи, LLM-агенты и GPU-инфраструктура под них. Делаю системы целиком, от пайплайна моделей и оценки качества до бэкенда продукта. До 2024 года 13 лет в веб-разработке, в том числе в VK (Delivery Club) и Яндексе (Яндекс Еда).

Опыт

AIGF, luv.club, adorely.co, sinly.io — Март 2026 – сейчас

Generative AI Engineer

- Платформы AI-компаньонов (18+) с генерацией фото, видео и 3D, чатом и голосом: мультитенантный бэкенд на Hono, воркеры Redis/BullMQ, GPU-задачи на RunPod.
- Фото с сохранением внешности на Qwen Image 2.1: LoRA для согласованных правок, до четырёх референсов и автоматическая перерисовка, если лицо «уплыло».
- Видео: text-to-video и image-to-video с двухпроходным сэмплированием и интерполяцией RIFE до 48 fps; замена лица и всего персонажа на MiniMax H3 со swap-LoRA.
- 3D-сцена в видео: референсный рендер задаёт только первые 5 из 20 шагов сэмплирования, так что камера и композиция сохраняются, а движение остаётся естественным.
- Память компаньонов: извлечение фактов LLM с исправлениями, гибридный поиск по эмбеддингам OpenAI в pgvector, лексическое переранжирование и оценка релевантности LLM.
- Проверка возраста на сгенерированных медиа: детекция лиц, ViT-классификатор возраста и логистический пробник на эмбеддингах CLIP, обученный на 9 574 примерах. На отложенных данных верные отказы выросли с 283 до 350 из 400, ложные упали с 26 до 3 из 302.
- Агенты на Grok с инструментами: режиссёр студии настраивает съёмки и проверяет результат, 3D-редактор правит сцены с валидацией и контролем ревизий; REST и MCP API с OAuth 2.1.
- Голос: свой TTS на CPU (Kokoro-82M в ONNX, 54 голоса) и распознавание на Whisper.

Funcorp, Кипр — Ноябрь 2024 – март 2026

Senior Product Developer

- Начинал с поддержки основного продукта, потом делал новые AI-продукты с нуля.
- Диффузионные пайплайны для фото и видео (Wan 2.2, LTX, SD, SDXL) в ComfyUI и DiffSynth-Studio; сбор датасетов и обучение LoRA.
- Синтез речи: дизайн голосов и дообучение модели для естественного звучания.
- LLM-функции на Qwen3.5-9B, ChatGPT и Grok; RAG на Qdrant.
- Данные и бэкенд: Kafka, ClickHouse, PostgreSQL, Redis, Next.js, Hono, FFmpeg.

ML-проекты

Studio, film.balkhaev.com

Производство AI-фильмов: агент-продюсер на Claude превращает идею в сценарий и поставленные кадры, рендерит референсные проходы в Blender через MCP и генерирует кадры на H3. Дубль принимается, только если прошёл декодирование кадров, проверку визуальной моделью и транскрибацию речи.

MediaPipes, mediapipes.balkhaev.com

Генерация фото, видео и речи на ComfyUI и vLLM: Qwen Image 2.1 INT8 с десятью референсами, тайловый апскейл до 8 Мп, Higgs TTS 3 (4B). INT8-attention для H3 ускорил сэмплирование с 13,0 до 6,8 с/шаг (задача замены: со 129 до 80 с) и попал в прод после замеров сходства лиц, липсинка, LPIPS и слепого сравнения.

Inference

Планировщик GPU для домашней RTX 5080 (ComfyUI, локальные LLM, Blender): допуск по измеренным пикам RAM и VRAM, совместный запуск только после трёх сопоставимых одиночных, прогретые модели и бюджеты, растущие после нехватки памяти.

Локальная LLM

Qwen3.8-Flash-Next (125B, GGUF) на одной RTX 5080 через Strata: эксперты распределены между VRAM, RAM и SSD, контекст 262k, около 100 токенов/с; шлюз с API OpenAI и Anthropic и маршрутизацией по аккаунтам.

Montage
Разбор видео: описания кадров от Qwen3-VL-4B, транскрипт WhisperX с выравниванием слов и склейки PySceneDetect в одном таймлайне, модели загружаются по очереди, чтобы уместиться в одну GPU; перекаст видео на H3.

Modeler, modeler.balkhaev.com
Персонажи и превиз в Blender: image-to-3D (TRELLIS.2, Pixal3D) в GLB с текстурами, text-to-motion на риге из 63 костей с проверкой контакта стоп, реконструкция лица по снимкам Qwen.

Веб-разработка

Яндекс, Москва — Октябрь 2022 – август 2024
Разработчик интерфейсов

- Перешёл из VK вместе с командой Delivery Club в рекламное направление Яндекс Еды: аналитика и быстрая проверка рекламных гипотез.
- Основной webview Яндекс Еды и Яндекс Вендора, микрофронтендная архитектура.
- Рекламный раннер, первым партнёром которого стал Haval на старте в России; почти вся баннерная реклама, отладка аналитики и новые метрики.

VK, Delivery Club — Июнь 2020 – октябрь 2022
Ведущий разработчик

- Поддерживал delivery-club.ru, фактически как full-stack: админки для партнёров и юристов, рекламные форматы, внутренние UI- и API-библиотеки.
- После инцидента сделал для юристов систему документов с версиями и аудит-логами.

Data-screen, Москва — Июнь 2019 – март 2020
Fullstack-разработчик

- Сервис спортивных трансляций по высокоуровневым идеям, все технические решения на мне (Node.js, React, PostgreSQL, Redis, Docker); проект остановил ковид.

Смарт Солюшн, Москва — Ноябрь 2015 – декабрь 2018
Senior Frontend Developer

- Фронтенд десятка высоконагруженных сайтов из топ-50 Alexa: переписывание legacy, оптимизация и сборка; рекламные интеграции; обучение верстальщиков и код-ревью.

Oversun, Веб-разработчик — 2014 – 2015
Сайты на WordPress с нуля, свои модули, руководство младшим верстальщиком.

Ideegroupe, Сочи, Веб-разработчик — 2013
WordPress и ModX: модули для городского новостного портала, оптимизация SQL.

RedBox, Бурятия, HTML-верстальщик — 2011 – 2012
Шаблоны для Joomla и WordPress, jQuery.

Навыки

Модели	Qwen Image, H3, Wan 2.2, LTX, SD, SDXL, TRELLIS.2, Kokoro, Higgs TTS, Whisper, Qwen3-VL
ML-инженерия	Обучение LoRA, датасеты, оценка (сходство лиц, LPIPS, липсинк), CLIP-пробники, эмбеддинги и RAG, INT8 и GGUF
Сервинг	ComfyUI, vLLM, ONNX Runtime, RunPod, планирование GPU, Redis/BullMQ
LLM и агенты	Tool use, MCP, Claude, GPT, Grok, Qwen, pgvector, Qdrant
Разработка	Python, TypeScript, Node.js, Bun, Hono, Next.js, React, PostgreSQL, ClickHouse, Kafka, Docker

Детали

Языки	Русский (родной), английский (выше среднего, B2)
Образование	Среднее
Формат	Полная или частичная занятость, проекты; удалённо, гибрид или офис; готов к переезду по России.