Михаил Бальхаев

ML Engineer / Generative AI Engineer / Product Developer

Москва m.balkhaev@gmail.com +7 966 006-60-68 t.me/balkhaev balkhaev.com



Разработчик, 14 лет опыта. Работал над Delivery Club в VK и Яндекс Едой в Яндексе, с 2024 года делаю продукты на генеративном AI: пайплайны генерации изображений и видео, обучение LoRA, синтез речи, RAG и локальный инференс LLM.

Опыт

AIGF, luv.club — Март 2026 – сейчас
Generative AI Engineer

- Делаю luv.club, платформу AI-компаньонов (18+) с генерацией фото и видео. Отвечаю за весь продукт: API на WebSocket, воркеры очередей, сайт и админку.
- Генерация фото и видео на RunPod с Qwen Image 2.1 и H3: персонажи, образы, сцены, FaceSwap.
- 3D в видео: референсный 3D-рендер управляет только первыми 5 из 20 шагов сэмплирования. Камера и композиция сохраняются, а движение модель делает естественным.
- API и MCP-сервер, через которые внешние агенты создают персонажей, сцены и съёмки.

Funcorp, Кипр — Ноябрь 2024 – март 2026
Senior Product Developer

- Начинал с поддержки основного продукта, потом перешёл на новые AI-продукты с нуля.
- Генерация изображений и видео: Wan 2.2, LTX, SD и SDXL в ComfyUI и DiffSynth-Studio; подготовка датасетов и обучение LoRA.
- Синтез речи: дизайн голосов и дообучение модели, чтобы речь звучала естественно.
- LLM и RAG: Qwen3.5-9B, ChatGPT, Grok, Qdrant.
- Next.js, Hono, Kafka, ClickHouse, PostgreSQL, Redis, FFmpeg.

Яндекс, Москва — Октябрь 2022 – август 2024
Разработчик интерфейсов

- Перешёл из VK вместе с командой Delivery Club в рекламное направление Яндекс Еды. Основная работа: аналитика и проверка рекламных гипотез.
- Поддерживал основной webview Яндекс Еды и Яндекс Вендора, улучшал микрофронтендную архитектуру.
- Сделал рекламный раннер с курьером. Первым партнёром стал Haval, который тогда выходил на российский рынок: курьера заменили машиной, вдоль дороги поставили рекламные щиты.
- Реализовал почти всю баннерную рекламу, отлаживал аналитику, предлагал новые метрики.

VK, Delivery Club — Июнь 2020 – октябрь 2022
Ведущий разработчик

- Поддерживал delivery-club.ru, фактически как full-stack.
- Делал админки для партнёров и юристов, новые рекламные форматы.
- Писал внутренние библиотеки: UI-компоненты и API-хелперы.
- После одного из инцидентов сделал админку для юристов с версионированием документов и аудит-логами.

Data-screen, Москва — Июнь 2019 – март 2020
Fullstack-разработчик

- Реализовывал идеи по высокоуровневому описанию, технические решения принимал сам. Основной проект, сервис спортивных трансляций, остановился из-за ковида.
- Node.js, Express, React, Docker, Redis, PostgreSQL, Nginx.

Смарт Солюшн, Москва — Ноябрь 2015 – декабрь 2018
Senior Frontend Developer

- Фронтенд десятка высоконагруженных сайтов из топ-50 Alexa (не SPA, много legacy): переписывание старого кода, оптимизация бизнес-логики, настройка сборки.
- Отвечал за рекламу: баннеры, web push, popunder.
- Обучал новых верстальщиков, проводил код-ревью, вёл техническую документацию.

Ранее

Oversun, Веб-разработчик — 2014 – 2015
Сайты на WordPress с нуля и собственные модули; корпоративный сайт компании с младшим верстальщиком под моим руководством.

Ideegroupe, Сочи, Веб-разработчик — 2013
WordPress и ModX: модули для городского новостного портала, оптимизация SQL.

RedBox, Бурятия, HTML-верстальщик — 2011 – 2012
Шаблоны для Joomla и WordPress, первые адаптивные вёрстки, jQuery.

Проекты

Inference. Очередь задач для домашней RTX 5080 и ноутбука с RTX 4080, которые работают как серверы генерации. Каждое задание резервирует ресурсы по средней нагрузке своего типа, модель не выгружается, если она нужна следующей задаче, а при свободных ресурсах задачи идут параллельно.

Локальная LLM. Qwen3.8-Flash-Next (125B) через Strata, около 100 токенов/с на RTX 5080 с 64 ГБ RAM. Харнесс DeepSeek Harness с плагином dsh-purge.

balkhaev.com. Падение в чёрную дыру Шварцшильда в браузере: трассировка лучей на WebGL в координатах Пенлеве–Гульстранда.

ggpick.club. SEO-сайт об играх, 200+ уникальных посетителей в день.

Навыки

Генеративный AI	Wan 2.2, LTX, SD, SDXL, Qwen Image, H3, ComfyUI, DiffSynth-Studio, обучение LoRA, TTS, FFmpeg
LLM	RAG, Qdrant, эмбеддинги, локальный инференс, агенты, MCP
Бэкенд	Node.js, Bun, Hono, Python, Django, Kafka, ClickHouse, PostgreSQL, Redis, Elasticsearch, MongoDB, GraphQL, REST, Docker
Фронтенд	TypeScript, React, Next.js, Vue, WebGL, микрофронтенды, Webpack, SEO

Языки

Русский: родной
Английский: начальный (A1)

Образование

Среднее

Формат работы

Полная или частичная занятость, проектная работа. Удалённо, гибрид или офис. Готов к командировкам и переезду по России.